

Panduan Lengkap Penggunaan Model Terlatih dari Repositori Pandora_MCCNN

Ringkasan Eksekutif

Laporan ini menyajikan panduan mendalam dan komprehensif untuk memanfaatkan model terlatih dari pustaka Pandora_MCCNN. Permintaan pengguna untuk panduan *end-to-end*, mulai dari impor hingga prediksi, memerlukan klarifikasi penting mengenai fungsi inti MCCNN. Model MCCNN bukanlah solusi lengkap yang menghasilkan peta *disparity* final dari sepasang gambar. Sebaliknya, ini adalah model PyTorch khusus yang dirancang untuk menghitung "biaya kecocokan" atau skor kesamaan antara pasangan *patch* gambar. Ini adalah langkah pertama yang sangat penting dalam alur kerja pencocokan stereo klasik yang membutuhkan langkah-langkah berikutnya seperti agregasi biaya dan optimasi untuk menghasilkan peta *disparity* akhir. Panduan ini akan menavigasi perbedaan ini, memberikan panduan praktis untuk instalasi, pemuatan model, inferensi, dan integrasi strategis dengan kerangka kerja Pandora yang lebih luas dan algoritma stereo lainnya.

1. Konsep Dasar Visi Stereo dan Peran MCCNN

Bagian ini bertujuan untuk membangun konteks teoretis yang diperlukan, memastikan pemahaman yang jelas tentang posisi MCCNN dalam domain visi stereo yang lebih luas.

1.1 Tantangan Visi Stereo: Dari Gambar ke Kedalaman

Visi stereo adalah masalah fundamental dalam visi komputer yang bertujuan untuk menentukan informasi kedalaman dari sebuah adegan dengan menggunakan dua gambar yang diambil dari sudut pandang yang sedikit berbeda. Ini dicapai dengan menghitung

disparity—perbedaan dalam posisi horizontal suatu titik yang sama pada gambar kiri dan kanan. Objek yang lebih dekat akan memiliki *disparity* yang lebih besar, sedangkan objek yang lebih jauh akan memiliki *disparity* yang lebih kecil. Perhitungan *disparity* yang akurat sangat penting untuk aplikasi yang beragam, termasuk rekonstruksi 3D, robotika, dan pencitraan geospasial.

1.2 Alur Kerja Pencocokan Stereo: Pendekatan Modular

Sebagian besar algoritma pencocokan stereo canggih mengikuti alur kerja empat langkah yang terinspirasi oleh taksonomi modular yang diusulkan oleh Scharstein dan Szeliski pada tahun 2002.¹

Pandora didesain secara eksplisit berdasarkan prinsip-prinsip ini.³ Memahami langkah-langkah ini sangat penting untuk menempatkan

MCCNN dengan benar.

1. **Perhitungan Biaya Kecocokan (Matching Cost Computation):** Langkah pertama ini, yang menjadi fokus utama dari model MCCNN, bertujuan untuk mengukur tingkat kesamaan atau ketidakmiripan antara setiap *pixel* atau *patch* dalam gambar kiri dan kandidat *pixel* atau *patch* yang berkorespondensi dalam gambar kanan. Hasilnya adalah matriks yang disebut volume biaya (*cost volume*).
2. **Agregasi Biaya (Cost Aggregation):** Langkah ini menggabungkan biaya kecocokan dari lingkungan lokal untuk menegakkan kendala kelancaran, mengasumsikan bahwa *pixel* yang berdekatan dalam gambar cenderung memiliki *disparity* yang sama.
3. **Optimasi (Optimization):** Proses ini memilih *disparity* terbaik untuk setiap *pixel* berdasarkan volume biaya yang telah diagregasi, seringkali dengan menerapkan kendala global atau lokal.
4. **Penyempurnaan Disparity (Disparity Refinement):** Langkah terakhir ini meningkatkan peta *disparity* awal dengan menyempurnakan nilai sub-piksel, mengisi daerah yang terhalang (*occlusions*), atau menerapkan filter tambahan.

1.3 Kerangka Kerja Pandora: Host Berkelas Produksi

Pandora bukanlah model tunggal, tetapi kerangka kerja pencocokan stereo yang fleksibel dan modular.² Kerangka kerja ini dirancang untuk tujuan penelitian dan produksi, memungkinkan pengguna untuk merancang, menganalisis, dan memodifikasi alur kerja pencocokan stereo

dengan kode yang minimal. Penggunaan

Pandora dalam rantai pemrosesan CNES & Airbus CO3D dan perannya sebagai alat inti dalam perangkat lunak CARS menunjukkan sifatnya yang kuat dan teruji di lingkungan nyata.³

Sangatlah penting untuk memahami bahwa Pandora_MCCNN beroperasi sebagai "plugin" atau modul khusus dalam ekosistem Pandora yang lebih besar.² Menganggap

MCCNN sebagai solusi *end-to-end* yang berdiri sendiri, seperti yang disiratkan dalam pertanyaan, dapat menyebabkan kebingungan. Model ini hanya melakukan langkah pertama—perhitungan biaya kecocokan—dan tidak akan menghasilkan peta *disparity* lengkap tanpa langkah-langkah berikutnya yang ditangani oleh kerangka kerja seperti Pandora. Oleh karena itu, laporan ini akan menempatkan MCCNN dengan tepat sebagai komponen spesialis yang mengaktifkan kemampuan kecocokan biaya berbasis AI dalam alur kerja yang sudah mapan.

2. Model MCCNN: Arsitektur dan Fungsionalitas Inti

Bagian ini menjelaskan dasar-dasar konseptual model MCCNN dan variannya, yang didasarkan pada riset fundamental.

2.1 Melampaui Metrik Buatan Tangan

Inovasi utama dari MCCNN adalah adopsi pendekatan "metrik mendalam" atau "jaringan Siamese" untuk perhitungan biaya kecocokan.⁵ Secara historis, algoritma stereo menggunakan metrik sederhana yang dibuat secara manual, seperti

Sum of Absolute Differences (SAD) atau *Normalized Cross-Correlation* (NCC), untuk menilai kemiripan *patch*. Sebaliknya, MCCNN dilatih untuk secara otomatis mempelajari fitur-fitur yang diskriminatif dan mengidentifikasi pasangan *patch* yang serupa dan tidak serupa.¹ Proses pelatihan dilakukan secara terawasi (

supervised) menggunakan dataset klasifikasi biner dari pasangan *patch* positif (mirip) dan negatif (tidak mirip).¹

2.2 Dua Arsitektur MCCNN: Fast vs. Accurate

Pustaka Pandora_MCCNN menyediakan dua varian utama dari model MCCNN yang telah dilatih sebelumnya: mc-cnn fast dan mc-cnn accurate.⁶ Perbedaan antara keduanya terletak pada kompromi antara efisiensi komputasi dan akurasi. Varian

fast dirancang untuk performa yang lebih cepat, sedangkan varian accurate mengoptimalkan presisi dengan biaya waktu pemrosesan yang lebih lama, sesuai dengan temuan dalam makalah penelitian aslinya.¹ Kedua arsitektur ini diimplementasikan menggunakan kerangka kerja PyTorch.⁶

2.3 Dataset Pelatihan: Middlebury dan Data Fusion Contest

Model terlatih MCCNN dikalibrasi menggunakan dua jenis dataset yang berbeda, yang menyoroti fleksibilitasnya untuk aplikasi yang beragam.⁶

- **Dataset Middlebury:** Ini adalah dataset klasik dan terkenal dalam komunitas riset visi komputer. Dataset ini menampilkan gambar stereo beresolusi tinggi dengan *ground truth* sub-piksel, menjadikannya tolok ukur yang standar untuk evaluasi algoritma stereo.¹
Model MCCNN yang dilatih pada dataset ini sangat cocok untuk penelitian akademik dan perbandingan kinerja.
- **Dataset Data Fusion Contest (DFC):** Dataset ini berfokus pada pencitraan satelit dan udara, mencerminkan aplikasi MCCNN dalam domain geospasial dan pengamatan Bumi.⁶
Model yang dilatih pada dataset ini lebih sesuai untuk kasus penggunaan di dunia nyata yang melibatkan pemrosesan data penginderaan jauh.

3. Panduan Implementasi Lengkap: Dari pip ke Prediksi

Bagian ini menyediakan panduan praktis dan terperinci untuk menggunakan model MCCNN yang telah dilatih sebelumnya.

3.1 Penyiapan Lingkungan dan Instalasi

Sebelum memulai, pastikan lingkungan yang tepat telah disiapkan. Persyaratan utama mencakup Python versi 3.8 atau yang lebih tinggi, yang merupakan prasyarat yang ditentukan dalam metadata PyPI.⁷ Sangat disarankan untuk menggunakan lingkungan virtual untuk mengelola dependensi. Instalasi

MCCNN dilakukan dengan menggunakan manajer paket pip, yang merupakan metode utama dan paling andal:

```
Bash
```

```
pip install MCCNN
```

3.2 Memperoleh dan Memuat Bobot Terlatih

Mengakses bobot terlatih adalah langkah penting. Meskipun repositori GitHub memberikan perintah wget untuk mengunduh file bobot, bobot tersebut juga terbungkus di dalam paket pip.⁶ Pengalaman menunjukkan bahwa tautan langsung untuk mengunduh file besar dapat menjadi tidak andal atau tidak dapat diakses.⁸ Oleh karena itu, metode kanonis dan paling kuat untuk mengakses bobot adalah melalui pustaka

mc_cnn yang terinstal secara lokal. Pendekatan ini memastikan konsistensi versi dan keandalan.

Tabel berikut merangkum konfigurasi bobot yang tersedia untuk memudahkan referensi:

Parameter arch	Parameter training_dataset	Nama File Bobot	Deskripsi
fast	middlebury	mc_cnn_fast_mb_w_eights.pt	Model cepat, dilatih dengan data Middlebury, cocok untuk prototyping atau skenario

			waktu nyata.
fast	dfc	mc_cnn_fast_data_fusion_contest.pt	Model cepat, dilatih dengan data geospasial DFC.
accurate	middlebury	mc_cnn_accurate_mb_weights.pt	Model akurat, dilatih dengan data Middlebury, optimal untuk presisi tinggi.

Untuk memuat model menggunakan metode kanonis, langkah-langkah berikut dapat diikuti:

1. Impor modul `get_weights` dari submodule `mc_cnn.weights`.⁶
2. Gunakan fungsi `get_weights()` untuk mengambil jalur ke file bobot yang diinginkan.
3. Gunakan PyTorch untuk memuat kamus status bobot.

Berikut adalah contoh kode Python yang mengilustrasikan proses ini:

Python

```
import torch
from mc_cnn.weights import get_weights
from mc_cnn.models import mccnn

# Dapatkan jalur ke bobot 'accurate' yang dilatih pada dataset 'middlebury'
weights_path = get_weights(arch="accurate", training_dataset="middlebury")

# Inisialisasi model MCCNN
model = mccnn.Mccnn(arch="accurate")

# Muat bobot yang telah dilatih
model.load_state_dict(torch.load(weights_path))

# Pindahkan model ke GPU jika tersedia
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
model.to(device)
```

3.3 Mempersiapkan Data Masukan untuk Inferensi

Model MCCNN dirancang untuk menerima sepasang *patch* gambar yang sudah diproses sebelumnya, bukan seluruh gambar stereo.¹ Untuk inferensi, data masukan harus berupa pasangan

patch yang diekstraksi dari gambar stereo yang telah direktifikasi. Pemrosesan ini mencakup normalisasi dan penyesuaian dimensi yang diperlukan.

3.4 Inferensi dan Interpretasi Hasil

Setelah model dimuat dan data masukan disiapkan, langkah berikutnya adalah menjalankan inferensi.

Python

```
# Asumsikan 'patch_left' dan 'patch_right' adalah tensor PyTorch dari patch gambar
# Mereka harus memiliki bentuk yang sesuai (batch_size, channels, height, width)
# Ganti dengan data nyata Anda
patch_left = torch.randn(1, 3, 9, 9).to(device)
patch_right = torch.randn(1, 3, 9, 9).to(device)

# Lakukan forward pass untuk mendapatkan skor kecocokan
with torch.no_grad():
    similarity_score = model(patch_left, patch_right)

print(f"Skor Kecocokan yang Dihasilkan: {similarity_score.item()}")
```

Sangat penting untuk diingat bahwa keluaran dari model MCCNN hanyalah skor kesamaan, seringkali dalam bentuk nilai logit.¹ Nilai ini mengukur seberapa miripnya sepasang

patch satu sama lain. Nilai ini harus dimasukkan ke dalam alur kerja yang lebih besar, di mana langkah-langkah selanjutnya (agregasi biaya, optimasi, dan penyempurnaan) akan

menggunakan skor ini untuk pada akhirnya menghasilkan peta *disparity* yang lengkap.

4. Integrasi Lanjutan dan Pertimbangan Strategis

Bagian ini mengangkat panduan dari tutorial dasar menjadi sumber daya tingkat ahli, memberikan wawasan tentang integrasi dan pengambilan keputusan.

4.1 Mengintegrasikan dengan Kerangka Kerja Stereo Pandora

Sebagai modul, MCCNN dirancang untuk berintegrasi secara mulus dengan kerangka kerja Pandora.³ Integrasi ini dicapai melalui instalasi plugin khusus menggunakan

pip:

```
Bash
```

```
pip install pandora[mccnn]
```

Perintah ini secara otomatis menginstal MCCNN dan semua dependensi yang diperlukan, memposisikannya sebagai modul biaya kecocokan dalam alur kerja Pandora.² Integrasi ini memungkinkan pengguna untuk memanfaatkan

MCCNN sebagai bagian dari alur kerja modular yang dapat dikonfigurasi, yang kemudian dapat dikombinasikan dengan algoritma agregasi dan optimasi yang berbeda.

4.2 Pilihan Strategis: Fast vs. Accurate

Pilihan antara arsitektur fast dan accurate tidak hanya tergantung pada spesifikasi teknis, tetapi juga pada persyaratan kasus penggunaan spesifik.¹ Keputusan yang tepat melibatkan analisis kompromi antara kecepatan dan presisi.

- **Pilih mc-cnn fast ketika:** Sumber daya komputasi terbatas atau kinerja waktu nyata (*real-time*) atau mendekati waktu nyata adalah prioritas. Skenario seperti ini umum dalam robotika, sistem *real-time* untuk kendaraan, atau untuk prototyping awal di mana kecepatan iterasi lebih penting daripada presisi mutlak.
- **Pilih mc-cnn accurate ketika:** Akurasi maksimum sangat penting, dan waktu pemrosesan tidak menjadi kendala utama. Hal ini berlaku untuk aplikasi di mana presisi geometris sangat penting, seperti dalam pemetaan geospasial, rekonstruksi 3D resolusi tinggi, atau aplikasi ilmiah lainnya. Model ini dirancang untuk mencapai presisi tertinggi yang mungkin dicapai.

5. Referensi Teknis Mendalam

Bagian ini menyediakan referensi teknis yang lebih terperinci untuk pengguna yang ingin tahu atau pengguna tingkat lanjut.

5.1 Di Bawah Kap: Prinsip Jaringan Siamese

Jaringan MCCNN pada dasarnya adalah jaringan Siamese.⁵ Ini terdiri dari dua cabang jaringan saraf yang identik yang berbagi bobot yang sama. Setiap cabang memproses satu gambar masukan (

patch kiri atau *patch* kanan) secara terpisah. Lapisan-lapisan jaringan ini secara progresif mengekstrak fitur-fitur yang semakin abstrak. Pada titik tertentu, representasi dari kedua *patch* tersebut dibandingkan, biasanya dengan menghitung perbedaan atau jarak antara vektor fitur yang diekstrak. Hasilnya kemudian dimasukkan ke dalam lapisan klasifikasi yang menentukan skor kesamaan akhir. Desain ini secara inheren memungkinkan jaringan untuk belajar membandingkan dua input dan memberikan skor kecocokan yang signifikan secara semantik, berbeda dengan metrik tradisional yang hanya mengandalkan nilai *pixel* atau fitur yang dibuat secara manual.

5.2 Pertimbangan Komputasi dan Etis

Penggunaan jaringan saraf tiruan yang mendalam untuk perhitungan biaya kecocokan

memperkenalkan persyaratan komputasi yang lebih besar dibandingkan dengan algoritma stereo tradisional. Meskipun menawarkan peningkatan akurasi, pengguna harus memiliki akses ke sumber daya yang memadai, seperti GPU, untuk melakukan inferensi secara efisien. Secara etis, pustaka Pandora_MCCNN dirilis di bawah lisensi Apache 2.0, yang memungkinkan penggunaan komersial, menjadikannya pilihan yang layak untuk perusahaan dan proyek penelitian.³ Lebih jauh lagi, penggunaan dataset seperti

DFC, yang berbasis pada pencitraan satelit dan udara, menyoroti implikasi yang lebih luas dari teknologi ini dalam aplikasi pengamatan Bumi, pemetaan, dan intelijen geospasial.

6. Kesimpulan dan Rekomendasi Masa Depan

Pandora_MCCNN adalah komponen penting dan canggih untuk perhitungan biaya kecocokan dalam alur kerja pencocokan stereo. Kekuatannya terletak pada kemampuannya untuk menggantikan metrik yang dibuat secara manual dengan model yang dilatih untuk mempelajari kemiripan, menghasilkan peningkatan akurasi yang signifikan dalam alur kerja yang sudah ada. Sifat modularnya, statusnya sebagai pustaka produksi, dan ketersediaan model terlatih untuk berbagai aplikasi (fast vs. accurate, Middlebury vs. DFC) menjadikannya alat yang sangat berharga bagi para peneliti dan profesional di bidang visi komputer.

Untuk pengguna, direkomendasikan untuk tidak menganggap MCCNN sebagai solusi *end-to-end*, melainkan sebagai modul biaya kecocokan yang kuat. Langkah selanjutnya yang paling logis adalah mengintegrasikan model ini dengan kerangka kerja Pandora menggunakan plugin `pandora[mccnn]` untuk menyelesaikan alur kerja pencocokan stereo secara keseluruhan dan menghasilkan peta *disparity* yang lengkap. Mengingat sifat dinamis dari bidang ini, disarankan untuk secara teratur memeriksa dokumentasi Pandora untuk pembaruan dan plugin tambahan.

Karya yang dikutip

1. Stereo Matching by Training a Convolutional Neural Network to Compare Image Patches - Journal of Machine Learning Research, diakses September 21, 2025, <https://www.jmlr.org/papers/volume17/15-535/15-535.pdf>
2. Getting started - Pandora documentation, diakses September 21, 2025, https://pandora.readthedocs.io/en/1.2.0/getting_started.html
3. CNES/Pandora: A stereo matching framework that will help you design your stereo matching pipeline with state of the art performances. - GitHub, diakses September 21, 2025, <https://github.com/CNES/Pandora>
4. pandora · PyPI, diakses September 21, 2025, <https://pypi.org/project/pandora/>
5. Review of Stereo Matching Algorithms Based on Deep Learning - PMC, diakses September 21, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC7125450/>

6. CNES/Pandora_MCCNN - GitHub, diakses September 21, 2025,
https://github.com/CNES/Pandora_MCCNN
7. MCCNN - PyPI, diakses September 21, 2025, <https://pypi.org/project/MCCNN/>
8. diakses Januari 1, 1970,
https://github.com/CNES/Pandora_MCCNN/tree/master/mc_cnn/weights
9. diakses Januari 1, 1970,
https://github.com/CNES/Pandora_MCCNN/tree/master/mc_cnn